

## Práctica 5: Series Temporales


Irene Extremera Serrano

29/03/2020

La serie temporal con la que voy a trabajar recopila información sobre fallecimientos causados por enfermedades que afectan al sistema genitourinario, procede del INE y va desde enero de 1980 a diciembre de 2017. El objetivo de esta práctica es analizar la serie temporal con estacionalidad por lo que haré uso de la serie mensual y seguiré la metodología de Box y Jenkins para identificar qué modelo ARIMA genera unas mejores predicciones.

```
# Librerías a usar
library(forecast)
library(tseries)
library(aod)
setwd('D:/Desktop/Remember/Estudios/Educación Formal/Máster/Máster Valencia/Bioestadística/Curso 1/20 2-6Modelización Estadística/Series Temporales/Practicas/P5')
# Serie Anual
enf_gu <- read.table('Enfermedades_del_sistema_genitourinario.txt', header = TRUE)
enf_mes <- ts(enf_gu, start = c(1980, 1), freq = 12)

#Gráfica de Las series
autoplot(enf_mes, main='Gráfica 1: Defunciones por enfermedades genitourinarias', ylab='Defunciones', xlab='Tiempo (meses)')
```




En la gráfica uno se muestra la serie temporal con estacionalidad y con tendencia. Como para realizar el siguiente análisis necesito que la serie sea estacionaria, ergódica y lo más homocedástica posible realizo varias funciones de autocorrelación para comprobar cuántas veces hay que diferenciar estacional y regularmente.


```
# Funciones de autocorrelación
```

```
par(mfrow=c(1,2))
acf(enf_mes, main = "Gráfica 2: Original", lag = 48)
acf(diff(enf_mes), main = "Gráfica 3:Regular", lag =48)
acf(diff(enf_mes,lag=12), main = "Gráfica 4:Estacional", lag = 48)
acf(diff(diff(enf_mes,lag=12)), main = "Gráfica 5:Estacional y regular",
lag = 48)
```


**Gráfica 2: Original**




**Gráfica 3:Regular**



**Gráfica 4:Estacional**



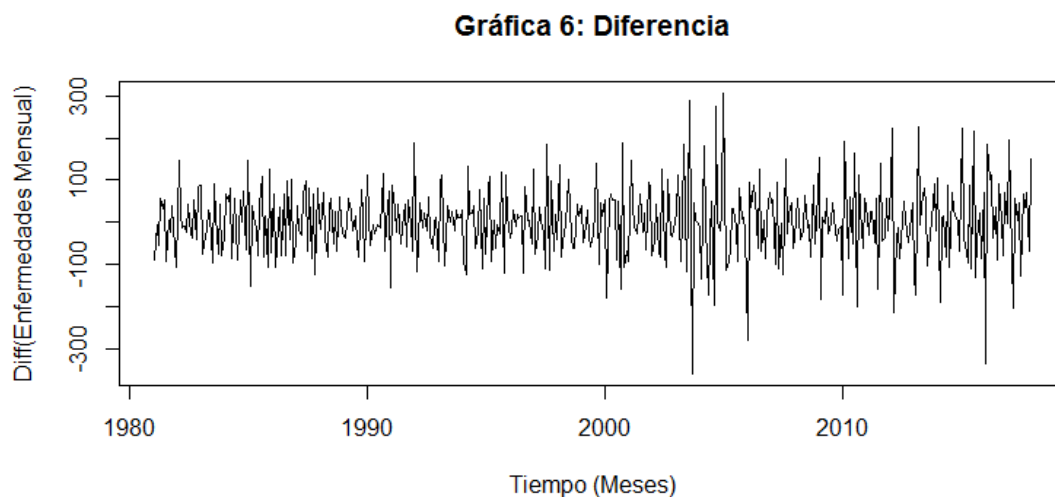
**Gráfica 5:Estacional y regular**



La diferenciación estacional-regular consigue una reducción muy rápida (estacionaria) y además la mayor parte de los valores quedan dentro del intervalo de confianza (ergódica), por lo que me quedo con esta. También podría considerar quedarme con la diferenciación estacional, pero tarda un poco más en decrecer en los primeros valores y prefiero por ello quedarme con la diferenciación estacional-regular.


Una vez que me he cerciorado de que la serie es estacionaria y ergódica realizando esa diferenciación dibujo un gráfico para ver cómo es la serie.

```
par(mfrow=c(1,1))
plot(diff(diff(enf_mes,lag=12)),main='Gráfica 6: Diferencia', ylab='Diff(
Enfermedades Mensual)', xlab='Tiempo (Meses)')
```



A la vista de la gráfica 6, he conseguido la estacionaridad en media con esta doble diferenciación ( $d=D=1$ ). Sin embargo, veo que no hay una estacionaridad en varianza ya que los valores van aumentando en dispersión a medida que el tiempo avanza. Por lo que realizaré el logaritmo de la serie para conseguir la estacionaridad en varianza también.

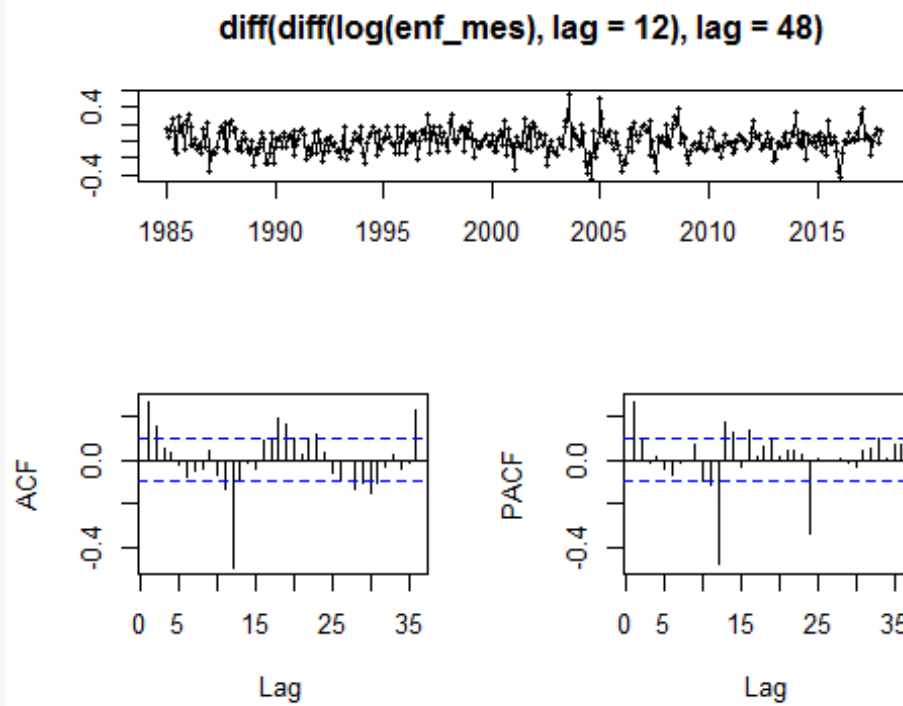
```
plot(diff(diff(log(enf_mes),lag=12)),main='Gráfica 7: Logaritmo de la diferencia', ylab='Diff(log(Enfermedades Mensual))', xlab='Tiempo (Meses)')
```



Como muestra la gráfica 6, efectivamente realizando el logaritmo de la serie consigo la estacionaridad en varianza para la serie temporal mensual.

Una vez conseguido que la serie sea estacionaria, ergódica y lo más homocedástica posible puedo comenzar con su identificación.

```
tsdisplay(diff(diff(log(enf_mes),lag=12),lag=48))
```



Lo que puedo observar en las distintas gráficas es que en la función de autocorrelación, en la parte regular hay un decrecimiento y un pico en  $ro_{12}$  en la parte estacional, mientras que en la función de autocorrelación parcial observo un decrecimiento en la parte estacional y decrecimiento en la parte regular. Aunque no se ve muy claramente deduzco que tengo un  $ARIMA(1,1,0)(0,1,1)$  o un  $ARIMA(0,1,1)(0,1,1)$ .

Sin embargo, el haber realizado el análisis completo de  $ARIMA(1,1,0)(0,1,1)$ , el cual no pasó las validaciones, y del modelo propuesto por autoarima  $(2,1,2)(2,1,0)$ , que pasaba las validaciones pero era muy complejo, probé con un modelo ligeramente más sencillo, un  $ARIMA(0,1,1)(0,1,1)$  obteniendo unas predicciones mejores.

La ecuación del modelo que voy a desarrollar es la siguiente:

$$ARIMA(0,1,1)(0,1,1)$$

$$(1 - L^{12})(1 - L)logy_t = c + (1 + \theta_1 L)(1 + \theta_{12} L^{12})\varepsilon_t$$

A continuación incluiré el desarrollo de la estimación y predicción del modelo  $ARIMA(0,1,1)(0,1,1)$  que es con el que me he quedado.

*#Realizo el  $ARIMA(0,1,1)(0,1,1)$  con  $\lambda = 0$  porque uso el logaritmo en la serie*

```
arima0 <- Arima(enf_mes,order=c(0,1,1),
               seasonal=list(order=c(0,1,1),period=12),
               lambda=0)

arima0


## Series: enf_mes
## ARIMA(0,1,1)(0,1,1)[12]
## Box Cox transformation: lambda= 0
##
## Coefficients:
##          ma1      sma1
##      -0.8223  -0.9993
## s.e.   0.0377   0.1143
##
## sigma^2 estimated as 0.004352:  log likelihood=554.46
## AIC=-1102.93   AICc=-1102.87   BIC=-1090.64
```

Ahora voy a mirar si hay algún valor atípico que merezca la pena incluir en el modelo.

*#Gráfica del residuo*

```
es <- sqrt(arima0$sig)
ts.plot(arima0$residuals, 2*es, -2*es, 3*es, -3*es,
       xlab = "Periodo",
       plot.type = "response",
       ylab = "",
       main = "Gráfica 8: Error de estimacion",
       lty = c(1, 2, 2, 2, 2),
       col = c("black", "red", "red", "blue", "blue"))
```

Gráfica 8: Error de estimacion



```
# Intervenciones
arima0$residuals > 3*es
arima0$residuals < -3*es
```

Se puede observar en la gráfica 8 que hay cinco valores que superan las tres desviaciones típicas por encima y por debajo por lo que sería necesario incluir esos valores en el modelo. Estos valores atípicos corresponden a: agosto de 2003, enero de 2005 y febrero de 2012.

Incluyo las intervenciones en su respectivo modelo y veo si significativas.

```
#arima0rima
d2003 <- rep(0, length(arima0$residuals)) #agosto
d2005 <- rep(0, length(arima0$residuals)) #enero
d2012 <- rep(0, length(arima0$residuals)) #febrero
ii <- order(abs(arima0$residuals), decreasing = TRUE)
d2003[ii[3]] <- 1
d2005[ii[2]] <- 1
d2012[ii[1]] <- 1

arima01 <- Arima(enf_mes, order= c(0,1,1), seasonal=list(order=c(0,1,1),per
iod=12), lambda=0, xreg=cbind(d2003,d2005,d2012))
arima01

## Series: enf_mes
## Regression with ARIMA(0,1,1)(0,1,1)[12] errors
## Box Cox transformation: lambda= 0
##
## Coefficients:
##          ma1          sma1      d2003      d2005      d2012
##         -0.8270      -1.0000      0.2247      0.2634      0.3457
## s.e.       0.0323       0.0622      0.0593      0.0594      0.0594
##
```

```
## sigma^2 estimated as 0.003795: log likelihood=586.16
## AIC=-1160.32 AICc=-1160.12 BIC=-1135.75

wald.test(b = coef(arima01), Sigma = vcov(arima01), Terms = 1)

## Wald test:
## -----
##
## Chi-squared test:
## X2 = 653.7, df = 1, P(> X2) = 0.0

wald.test(b = coef(arima01), Sigma = vcov(arima01), Terms = 2)

## Wald test:
## -----
##
## Chi-squared test:
## X2 = 258.2, df = 1, P(> X2) = 0.0

wald.test(b = coef(arima01), Sigma = vcov(arima01), Terms = 3)

## Wald test:
## -----
##
## Chi-squared test:
## X2 = 14.3, df = 1, P(> X2) = 0.00015

wald.test(b = coef(arima01), Sigma = vcov(arima01), Terms = 4)

## Wald test:
## -----
##
## Chi-squared test:
## X2 = 19.6, df = 1, P(> X2) = 9.3e-06


wald.test(b = coef(arima01), Sigma = vcov(arima01), Terms = 5)

## Wald test:
## -----
##
## Chi-squared test:
## X2 = 33.9, df = 1, P(> X2) = 5.9e-09
```

Todos los coeficientes asociados a los valores atípicos son significativos y los coeficientes  $ma1$  y  $sma1$  son significativos, por lo que todo ha de incluirse en el modelo ARIMA(0,1,1) (0,1,1) mejorado.

Una vez mejorado el modelo vuelvo a comprobar si tiene valores atípicos.

```
#Gráfica del residuo
arima02 <- Arima(enf_mes,order=c(0,1,1),
                 seasonal=list(order=c(0,1,1),period=12),
                 lambda=0,
                 xreg=cbind(d2003,d2005,d2012))
es <- sqrt(arima02$sig)
ts.plot(arima02$residuals, 2*es, -2*es, 3*es, -3*es,
        xlab = "Periodo",
        plot.type = "response",
        ylab = "",
        main = "Gráfica 9: Error de estimacion",
        lty = c(1, 2, 2, 2, 2),
        col = c("black", "red", "red", "blue", "blue"))
```



```
# Intervenciones
arima02$residuals > 3*es
arima02$residuals < -3*es
```

En la gráfica nueve se observa que en el modelo mejorado aun hay dos valores atípicos, uno corresponde con junio de 1986 y otro con febrero de 2012. El valor atípico de 2012 ya está incluido por lo que el valor que voy a meter en el modelo va a ser el de junio de 1986.

```
#arima02rima
d1986 <- rep(0, length(arima0$residuals)) #junio

ii <- order(abs(arima0$residuals), decreasing = TRUE)
d1986[ii[456]] <- 1

arima03 <- Arima(enf_mes,order= c(0,1,1),seasonal=list(order=c(0,1,1),period=12),lambda=0,xreg=cbind(d2003,d2005,d2012,d1986))
```



```

arima03

## Series: enf_mes
## Regression with ARIMA(0,1,1)(0,1,1)[12] errors
## Box Cox transformation: lambda= 0
##
## Coefficients:
##          ma1      sma1    d2003    d2005    d2012    d1986
##        -0.8278  -1.000    0.2248    0.2636    0.3459   -0.0504
## s.e.    0.0323    0.058    0.0593    0.0594    0.0594    0.0593
##
## sigma^2 estimated as 0.003797:  log likelihood=586.52
## AIC=-1159.04  AICc=-1158.78  BIC=-1130.38

wald.test(b = coef(arima03), Sigma = vcov(arima03), Terms = 1)

## Wald test:
## -----
##
## Chi-squared test:
## X2 = 656.5, df = 1, P(> X2) = 0.0

wald.test(b = coef(arima03), Sigma = vcov(arima03), Terms = 2)

## Wald test:
## -----
##
## Chi-squared test:
## X2 = 297.6, df = 1, P(> X2) = 0.0

wald.test(b = coef(arima03), Sigma = vcov(arima03), Terms = 3)

## Wald test:
## -----
##
## Chi-squared test:
## X2 = 14.4, df = 1, P(> X2) = 0.00015

wald.test(b = coef(arima03), Sigma = vcov(arima03), Terms = 4)

## Wald test:
## -----
##
## Chi-squared test:
## X2 = 19.7, df = 1, P(> X2) = 9.1e-06

```

```
wald.test(b = coef(arima03), Sigma = vcov(arima03), Terms = 5)

## Wald test:
## -----
##
## Chi-squared test:
## X2 = 33.9, df = 1, P(> X2) = 5.7e-09

wald.test(b = coef(arima03), Sigma = vcov(arima03), Terms = 6)

## Wald test:
## -----
##
## Chi-squared test:
## X2 = 0.72, df = 1, P(> X2) = 0.4
```

Se observa que todos los coeficientes salen significativos a excepción de junio de 1986 con un p valor de 0.4 por lo que no lo incluiré en el modelo definitivo.

La ecuación definitiva por lo tanto será la siguiente:

$$\text{ARIMA}(0,1,1)(0,1,1)$$

$$(1 - L^{12})(1 - L)\log y_t = (1 + \theta_1 L)(1 + \theta_{12} L^{12})\varepsilon_t + AI_1 d2003 + AI_2 d2005 + AI_3 d2012$$

$$TVAnual y_t = TVAnual y_{t-1} + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_{12} \varepsilon_{t-12} + \theta_1 \theta_{12} \varepsilon_{t-13} + AI_1 d2003 + AI_2 d2005 + AI_3 d2012$$

$$TVAnual y_t = TVAnual y_{t-1} + \varepsilon_t + (-0.83)\varepsilon_{t-1} + (-1)\varepsilon_{t-12} + (-0.83)(-1)\varepsilon_{t-13} + 0.22d2003 + 0.26d2005 + 0.34d2012$$

$$\widehat{TVAnual y}_t = TVAnual y_{t-1} + (-0.83)\varepsilon_{t-1} + (-1)\varepsilon_{t-12} + (-0.83)(-1)\varepsilon_{t-13} + 0.22d2003 + 0.26d2005 + 0.34d2012$$

La tasa de variación anual del número de fallecimientos a causa de enfermedades que afectan al sistema genitourinario se mantiene constante con respecto al periodo anterior ( $TVAnual = TVAnual_{t-1}$ )

Si la tasa de variación anual del mes previo fue anómala ( $\varepsilon_{t-1}$  diferente de cero) o la tasa de variación anual de hace un año fue anómala ( $\varepsilon_{t-12}$  diferente de cero), corrijo para compensar (términos en medias móviles).

Aparte, por alguna causa que desconozco en 2003, 2005 y 2012 hubo respectivamente un 22%, 26% y 34% más de fallecimientos de lo que se esperaba para ese año.

*#Calidad del modelo*  
**accuracy(arima02)**

```
##           ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
## Training set 1.645685 43.20709 32.55196 -0.1647271 4.661491 0.6041749 0.1235425
```

No se puede contrastar i el residuo tiene media cero pero el error medio es 1.646.

```
#Homocedasticidad
Box.test(arima02$residuals^2, lag=2, type='Ljung-Box')
## Box-Ljung test
##
## data: arima02$residuals^2
## X-squared = 0.31781, df = 2, p-value = 0.8531

Box.test(arima02$residuals^2, lag=24, type='Ljung-Box')
## Box-Ljung test
##
## data: arima02$residuals^2
## X-squared = 35.409, df = 24, p-value = 0.06257
```

Se acepta que el residuo es homocedástico (para lag 2 p valor de 0.85 y para lag 24, 0.0625).

```
#Incorrelación
Box.test(arima02$residuals, lag=2, type='Ljung-Box')
## Box-Ljung test
##
## data: arima02$residuals
## X-squared = 5.4255, df = 2, p-value = 0.06635

Box.test(arima02$residuals, lag=24, type='Ljung-Box')
## Box-Ljung test
##
## data: arima02$residuals
## X-squared = 31.724, df = 24, p-value = 0.134
```

El residuo es incorrelado (para lag 2 p valor de 0.066 y para lag 24, 0.134)

```
#Normalidad
jarque.bera.test(arima02$residuals)
##
## Jarque Bera Test
##
## data: arima02$residuals
## X-squared = 3.4852, df = 2, p-value = 0.1751
```

Para un p valor de 0.175 se acepta la hipótesis de normalidad.

Una vez que el modelo ha sido validado puedo ver cómo de bueno es para realizar predicciones.

```
accuracy(arima02)
##
## Training set 1.645685 43.20709 32.55196 -0.1647271 4.661491 0.6041749 0.1235425
```

Para empezar el MAPE es de 4.66% lo cual quiere decir que el modelo es bueno a la hora de realizar predicciones. Además, el ACIF1 es bastante bajo, de 0.12, lo cual

indica que la capacidad de mejora de las predicciones por intervalo es bastante baja. Aparte, en media el modelo se equivoca 43.20 casos (RMSE).

A continuación realizaré una predicción del número de fallecimientos a tres años vista y su intervalo al 80 y 95.

#### #Predicción

```
parima02 <- forecast(arima02, h=36, level =c(80,95), xreg = cbind(rep(0,36),rep(0,36),rep(0,36)))
```

parima02

##	Point	Forecast	Lo 80	Hi 80	Lo 95	Hi 95
## Jan 2018		1328.561	1226.4293	1439.198	1175.5816	1501.448
## Feb 2018		1182.515	1090.3145	1282.512	1044.4533	1338.826
## Mar 2018		1190.882	1096.7449	1293.099	1049.9625	1350.715
## Apr 2018		1083.325	996.5398	1177.669	953.4491	1230.893
## May 2018		1082.096	994.2770	1177.672	950.7111	1231.639
## Jun 2018		1028.974	944.4045	1121.116	902.4871	1173.188
## Jul 2018		1142.005	1046.9839	1245.649	999.9266	1304.270
## Aug 2018		1103.178	1010.2812	1204.616	964.3146	1262.038
## Sep 2018		1003.977	918.4406	1097.480	876.1510	1150.453
## Oct 2018		1050.016	959.5314	1149.033	914.8322	1205.176
## Nov 2018		1090.396	995.3799	1194.481	948.4806	1253.544
## Dec 2018		1260.252	1149.2353	1381.993	1094.4819	1451.130
## Jan 2019		1361.541	1239.9138	1495.098	1179.9904	1571.024
## Feb 2019		1211.869	1102.4330	1332.168	1048.5603	1400.612
## Mar 2019		1220.444	1109.0606	1343.013	1054.2740	1412.804
## Apr 2019		1110.217	1007.8397	1222.994	957.5231	1287.261
## May 2019		1108.958	1005.6557	1222.871	954.9252	1287.836
## Jun 2019		1054.517	955.3077	1164.028	906.6256	1226.532
## Jul 2019		1170.353	1059.1727	1293.204	1004.6589	1363.374
## Aug 2019		1130.562	1022.1366	1250.490	969.0144	1319.043
## Sep 2019		1028.899	929.3002	1139.173	880.5400	1202.255
## Oct 2019		1076.081	970.9593	1192.584	919.5344	1259.279
## Nov 2019		1117.463	1007.3170	1239.653	953.4748	1309.655
## Dec 2019		1291.536	1163.1090	1434.143	1100.3772	1515.902
## Jan 2020		1395.339	1255.0090	1551.359	1186.5295	1640.895
## Feb 2020		1241.951	1115.9417	1382.190	1054.4973	1462.728
## Mar 2020		1250.739	1122.7351	1393.337	1060.3654	1475.292
## Apr 2020		1137.776	1020.3402	1268.729	963.1626	1344.046
## May 2020		1136.486	1018.2005	1268.512	960.6523	1344.503
## Jun 2020		1080.693	967.2899	1207.392	912.1574	1280.369
## Jul 2020		1199.405	1072.5277	1341.292	1010.8898	1423.076
## Aug 2020		1158.627	1035.0899	1296.908	975.1183	1376.670
## Sep 2020		1054.440	941.1345	1181.387	886.1692	1254.663
## Oct 2020		1102.793	983.3820	1236.704	925.4964	1314.054
## Nov 2020		1145.202	1020.2632	1285.441	959.7406	1366.502
## Dec 2020		1323.596	1178.1225	1487.032	1107.7020	1581.568

```

#Diferencia de un año a otro por meses
parima02$mean[1:12]-parima02$mean[13:24]

## [1] -32.97937 -29.35400 -29.56170 -26.89178 -26.86128 -25.54260 -28.34840
## [8] -27.38459 -24.92210 -26.06493 -27.06729 -31.28370

parima02$mean[13:24]-parima02$mean[25:36]

## [1] -33.79802 -30.08266 -30.29552 -27.55933 -27.52807 -26.17665 -29.05210
## [8] -28.06437 -25.54075 -26.71195 -27.73919 -32.06027

# Meses en los que el número de fallecimientos es mayor y menor por año
which.max(parima02$mean[1:12])
## [1] 1
which.max(parima02$mean[13:24])
## [1] 1
which.max(parima02$mean[25:36])
## [1] 1
which.min(parima02$mean[1:12])
## [1] 9
which.min(parima02$mean[13:24])
## [1] 9
which.min(parima02$mean[25:36])
## [1] 9

```

En los distintos años predichos se observa que tanto el número de fallecimientos como su intervalo es mayor en los meses más fríos en especial en enero y más bajos en meses con temperaturas más suaves como septiembre. Otra cosa que queda por mencionar es que hay un incremento progresivo en el número de fallecimientos de un año a otro, por lo que la tendencia es positiva.


Para verlo de forma gráfica:

```

autoplot(parima02, ylab='Casos de fallecimientos',xlab='Tiempo (meses)',
xlim=c(2000,2020),main='Gráfica 10: Predicción a tres años vista')

```

Gráfica 10: Predicción a tres años vista



En la gráfica 10 se puede observar lo mencionado anteriormente, el número de fallecimientos aumenta de un año para otro lo cual hace que la tendencia sea positiva y en los tres años coinciden los meses con más número de muertes (enero) y con menos (septiembre).

Para finalizar la práctica haré una comparación con el modelo de alisado obtenido en la práctica 2.

```
enf_ets <- ets(enf_mes)
summary(enf_ets)

## ETS(M,A,M)
##
## Call:
## ets(y = enf_mes)
##
## Smoothing parameters:
##   alpha = 0.2026
##   beta  = 1e-04
##   gamma = 1e-04
##
## Initial states:
##   l = 439.5583
##   b = 1.3845
##   s = 1.0986 0.9523 0.9181 0.8804 0.9851 1.0087
##        0.9091 0.9574 0.9637 1.0594 1.0631 1.204
##
```

```
## sigma: 0.0672
##
## AIC AICc BIC
## 6293.591 6294.988 6363.673
##
## Training set error measures:
## ME RMSE MAE MPE MAPE MASE ACF1
## Training set 0.6504983 48.41639 34.6059 -0.3850739 4.945122 0.6422966 0.1147674
```

El valor de MAPE (error porcentual absoluto medio) es de 4.945% lo cual indica que la calidad de predicción del modelo es muy alta, sin embargo, la del modelo ARIMA es ligeramente mejor 4.66%. Aparte, el valor de MASE es del 0.642% por lo que el modelo de alisado no es mucho mejor con respecto al modelo más sencillo que podría aplicarse. Para terminar el ACF1 toma un valor de 0.115% ligeramente inferior al anterior, 0.12 y el RMSE en alisado es de 48.41 y de 43.20 en ARIMA.

Con el objetivo de analizar finamente la calidad del ajuste, voy a estimar el error según el horizonte temporal mediante la aplicación del procedimiento de origen de predicción móvil. Por ello voy a usar cinco años para la estimación del error y predecir en un horizonte temporal de 12 meses.

```
k <- 60 #Mínimo número de datos para estimar
h <- 12 #Horizonte de las predicciones
T <- length(enf_mes) #Longitud serie
s<-T - k - h #Total de estimaciones

mapeArima <- matrix(NA, s, h)
mapeAlisado <- matrix(NA, s, h)

X <- cbind(d2003,d2005,d2012) #Valores atípicos

for (i in 0:s) {
  train.set <- subset(enf_mes, start = i + 1, end = i + k)
  test.set <- subset(enf_mes, start = i + k + 1, end = i + k + h)

  X.train <- X[(i + 1):(i + k),]
  hay <- colSums(X.train)
  X.train <- X.train[, hay>0]

  X.test <- X[(i + k + 1):(i + k + h),]
  X.test <- X.test[, hay>0]

  if (length(X.train) > 0) {
    fit <- try(Arima(train.set,
                     order = c(0, 1, 1),
                     seasonal = list(order = c(0, 1, 1), period = 12),
                     lambda = 0, #
                     xreg=X.train), silent = TRUE)} else {
      fit <- try(Arima(train.set,
                       order = c(0, 1, 1),
```

```

        seasonal=list(order=c(0,1,1),period= 12),
        lambda = 0),
        silent = TRUE)
    }

    if (!is.element("try-error", class(fit))) {
      if (length(X.train) > 0) fcast <- forecast(fit, h = h, xreg = X.test)
    else
      fcast <- forecast(fit, h = h)
      mapeArima[i,] <- 100*abs(test.set - fcast$mean)/test.set}

    fit <- ets(train.set, model = "MAM", damped = FALSE)
    fcast<-forecast(fit, h = h)
    mapeAlisado[i,] <- 100*abs(test.set - fcast$mean)/test.set}

errorArima <- colMeans(mapeArima, na.rm = TRUE)
errorArima

## [1] 5.512621 5.806408 5.912495 5.842077 5.869323 5.923227 5.925331 5.942259
## [9] 5.912545 6.099003 6.204672 6.373606

errorAlisado <- colMeans(mapeAlisado)
errorAlisado


## [1] 5.532467 5.899591 5.975203 5.983157 6.006476 6.223820 6.262532 6.403772
## [9] 6.492914 6.703717 6.825096 7.027012

plot(errorAlisado,
     type = 'l',col = 'red', lwd = 2, lty = 2,
     xlab = 'Horizonte de prevision (meses)', ylab = '%',
     main = 'Gráfica 11:MAPE segun horizonte de prevision',
     xaxp = c(1,12,11), yaxp = c(2,4,4))
lines(errorArima,
     col = "blue", lwd = 2, lty = 1)
legend("topleft", legend = c("ARIMA","Alisado"),
     col = c("Blue","Red"), lwd = 2, lty = c(1, 2), cex = .9)

```



**Gráfica 11:MAPE segun horizonte de prevision**



En la gráfica 11 se refleja cómo en ambos métodos el MAPE aumenta de forma progresiva tanto en alisado como en ARIMA. En predicciones a un mes o dos vista el modelo de alisado (5.53% y 5.89%) obtiene predicciones muy similares a las que hace ARIMA (5.51% y 5.80%). Sin embargo, a largo plazo parece que el error del modelo ARIMA es menor que el error que comete alisado, 6.37% frente a 7.03%. Se puede observar como en el modelo ARIMA el error se mantiene mas o menos constante prediciendo de 3 a nueve meses vista y a partir de ahí se incrementa progresivamente.

Para concluir, en caso de tener que decantarme por algún modelo me decantaría sin duda por el de alisado debido a que es muchísimo más sencillo de obtener y las predicciones que da son similares a las del ARIMA a corto plazo. Sin embargo, en caso de querer hacer predicciones a largo plazo, elegiría el ARIMA sin dudarlo aunque sea más costoso de obtener.